

Análisis financiero y predicción de tendencias

EFP seleccionado: caso de la empresa de análisis de datos financieros del trabajo final. **Solución desarrollada:** Mercado Lab.

El enunciado no identifica razón social, RUC, ubicación, tamaño ni ventas. Se trabaja con una empresa del caso académico; no se atribuyen datos ficticios a una organización real. GGAL es el activo analizado y no debe confundirse con la empresa que utilizaría la solución.

1. Datos de la empresa y núcleo del negocio

Aspecto	Descripción aplicada al caso
Sector	Servicios de análisis de información financiera.
Qué hace (core)	Transforma datos de mercado en análisis y estimaciones que apoyan la toma de decisiones.
Cómo lo hace	Recibe archivos CSV, prepara sus datos, estudia tendencias y presenta resultados a sus usuarios. El caso indica que dispone de analistas y busca incorporar Machine Learning y Deep Learning.
Propuesta de operación	Con Mercado Lab, el analista usa un panel web para cargar datos, comparar modelos y consultar gráficos e informes. Los resultados pasan por revisión humana.

2. Problemática identificada

La empresa maneja volúmenes de datos financieros en CSV, pero carece de una metodología eficiente y uniforme de preprocesamiento, análisis y visualización. También necesita evaluar modelos predictivos y aprovechar información contenida en reportes financieros.

Esta situación puede generar preparación manual repetitiva, criterios diferentes entre analistas y comparaciones poco consistentes entre modelos. Son riesgos derivados del problema descrito; no se dispone de mediciones de pérdidas económicas o tiempos operativos reales.

3. Objetivo de mejora

Objetivo general: implementar un proceso reproducible que transforme datos históricos de un activo en información preparada, estime la dirección de su próximo cierre y evalúe esa estimación para apoyar el trabajo del analista financiero.

Objetivos específicos: validar el CSV; calcular indicadores relevantes; comparar clasificadores bajo las mismas fechas de prueba; extraer términos y cifras de un reporte; y producir un panel e informe con procedimientos, resultados y limitaciones.

Criterio de evaluación: contrastar exactitud, precision, recall y F1 frente a una referencia simple. Para medir la mejora operativa, la empresa deberá comparar el tiempo por análisis y el retrabajo antes y después de adoptar la herramienta. No se afirma un ahorro todavía no medido.

4. Recopilación y matriz de datos

Fuente disponible: archivo arch_financiero.csv recibido con el proyecto. Contiene 6.014 registros de GGAL, del 25/07/2000 al 20/06/2024. El usuario no dispone del enlace de origen; proveedor, licencia, moneda y ajustes históricos no están verificados.

Unidad de observación: una sesión bursátil de un activo. Se validan fechas, columnas y coherencia de precios; se eliminan duplicados exactos y se rechazan valores inválidos. Los indicadores usan solo datos disponibles hasta la sesión observada.

La preparación deja **5.984 observaciones útiles**: se pierden 29 por el calentamiento de la media móvil más larga y una por no tener cierre siguiente. Cada fecha conecta las dos tablas siguientes, que juntas muestran las nueve variables independientes y la variable objetivo.

Matriz A. Precios e identificación de la respuesta (filas reales)

Fecha	Apertura	Máximo	Mínimo	Cierre	Y
2000-09-05	17.8750	17.8750	17.4375	17.4375	0
2000-09-06	17.5000	17.6250	17.1406	17.3125	0
2000-09-07	17.5000	17.7500	16.6875	16.7500	1
2000-09-08	16.6875	16.8125	16.6875	16.8125	0
2000-09-11	16.7500	16.8125	16.6250	16.6250	0

Matriz B. Indicadores calculados de esas mismas observaciones

Fecha	$\ln(1 + \text{volumen})$	Retorno (%)	Dist. MA7 (%)	Dist. MA30 (%)	Volatilidad 7 (p.p.)
2000-09-05	10.6874	-1.4134	2.5735	4.7691	2.0960
2000-09-06	10.8376	-0.7168	1.1476	4.0571	2.1872
2000-09-07	12.5883	-3.2491	-2.3425	0.8277	2.6570
2000-09-08	8.3190	0.3731	-2.2326	1.3437	2.6550
2000-09-11	10.0124	-1.1152	-3.2225	0.3647	2.6402

Y = 1 indica subida del cierre siguiente; Y = 0, bajada o igualdad. Los indicadores se almacenan como proporciones; aquí retorno y distancias se muestran en porcentaje, y la desviación de retornos en puntos porcentuales. Las tablas están redondeadas para lectura.

Organización de los datos para evaluar

Entrenamiento: 3.589 filas para aprender relaciones; **validación: 1.196** para seleccionar pesos de las redes; **prueba: 1.197** para medir el desempeño final. La logística selecciona su regularización mediante validación temporal dentro del entrenamiento.

Se reserva aproximadamente 60/20/20 en orden cronológico. Dos filas adicionales se excluyen en las fronteras para que sus etiquetas no crucen al siguiente conjunto. El escalador se ajusta únicamente en entrenamiento.

5. Variable dependiente

Nombre: Objetivo (Y). **Tipo:** categórica binaria. **Definición:** vale 1 si el cierre de la siguiente sesión es mayor que el cierre actual; de lo contrario, vale 0.

Predicción planteada: al cierre de la sesión t , estimar la probabilidad de que el cierre de la próxima sesión bursátil suba. Con probabilidad estimada mayor o igual a 0,50 se clasifica como subida; por debajo de 0,50, como bajada o igualdad.

Ejemplo real: el 07/09/2000 el cierre fue 16,75 y el de la siguiente sesión fue 16,8125; por tanto, $Y = 1$. El cierre siguiente sirve para crear la etiqueta y evaluar, pero nunca entra como predictor.

El programa actual entrena y evalúa históricamente. No consume cotizaciones en vivo ni ofrece todavía un flujo específico para predecir la sesión posterior al último dato del CSV. No estima el precio exacto ni ejecuta compras o ventas.

6. Variables independientes y su importancia

Variable (X)	Descripción	Por qué se incluye
open	Precio de apertura de la sesión.	Describe el nivel inicial de negociación; junto al cierre puede representar el movimiento intradiario.
high	Precio máximo de la sesión.	Aporta información sobre el extremo superior alcanzado durante la negociación.
low	Precio mínimo de la sesión.	Describe el extremo inferior; junto a high ayuda a representar la amplitud intradiaria.
close	Precio final de la sesión.	Es la referencia del estado actual y de la definición de subida en la siguiente sesión.
Log_Volumen	$\ln(1 + \text{volumen negociado})$.	Representa actividad de negociación y comprime diferencias grandes de escala.
Retorno	Cierre actual / cierre anterior - 1.	Resume la dirección e intensidad del movimiento más reciente.
Distancia_MA7	Cierre / media de 7 sesiones - 1.	Ubica el precio respecto de su comportamiento reciente.
Distancia_MA30	Cierre / media de 30 sesiones - 1.	Añade una referencia temporal más amplia para contrastar la tendencia corta.
Volatilidad_7	Desviación estándar de retornos de 7 sesiones.	Describe variabilidad reciente y condiciones de mayor o menor fluctuación.

Alcance de la importancia: las razones anteriores justifican la selección conceptual de cada variable; no son resultados de una medición de importancia ni pruebas de causalidad. Debe evaluarse su contribución real con experimentos adicionales.

Date ordena y separa las observaciones; ticker identifica el activo. No son predictores del modelo actual. adjclose no se utiliza. Las medias móviles se calculan como apoyo, pero los modelos reciben sus distancias relativas. La LSTM agrupa las mismas nueve variables en ventanas de 20 sesiones.

7. Utilidad y aporte a la empresa

¿La predicción es útil? Sí, como hipótesis cuantitativa para que el analista compare escenarios y evalúe técnicas sobre datos históricos. Su utilidad operativa depende de que demuestre una ventaja estable fuera de los datos usados para aprender. Los resultados actuales no justifican automatizar decisiones de inversión.

Aporte	Aplicación y forma de comprobarlo
Preparación uniforme	Automatiza validaciones e indicadores. Medir errores detectados y retrabajo frente al proceso anterior.
Productividad	Genera métricas, gráficos e informe en un flujo. Comparar tiempo total por análisis antes y después.
Selección de modelos	Contrasta técnicas simples y redes sobre las mismas fechas; evita elegir una arquitectura solo por su complejidad.
Trazabilidad	Conserva resultados, configuración, versiones y modelos. Permite revisar qué se hizo y reproducir el análisis.
Lectura documental	NLP localiza términos y candidatos a cifras por página; facilita una revisión dirigida del reporte.

Evidencia obtenida y límites de la predicción

Modelo	Exactitud	Recall de subida
Referencia mayoritaria	50,21 %	0,00 %
Regresión logística	50,38 %	22,15 %
Red PyTorch	49,87 %	0,00 %
LSTM con Keras	52,21 %	7,05 %

La LSTM obtuvo la mayor exactitud de esta ejecución, pero detectó solo **42 de 596 subidas reales**. Anunció 60 subidas y acertó 42 (precision del 70 %); omitió las otras 554. Por ello, una exactitud de 52,21 % no demuestra por sí sola una capacidad suficiente para identificar oportunidades ni rentabilidad.

No se midieron significancia estadística, comisiones ni rendimiento de una estrategia. Se necesita validar en períodos nuevos, confirmar la procedencia del CSV y mejorar la detección antes de un uso operativo.

Flujo de uso y aporte complementario del NLP

Analista en el panel web / CSV validado / indicadores / separación temporal / entrenamiento y evaluación / métricas, gráficos e informe / revisión humana. Cada ejecución web conserva sus resultados por separado.

El reporte público de Galicia de 2Q2024 se analiza con tokenización y TF-IDF, detectando también porcentajes y montos. Fue publicado después del final del CSV y **no alimenta las predicciones**. Si se carga otro ticker, el reporte incluido sigue siendo el de Galicia. No se presenta un modelo de sentimiento validado.

Fuentes y alcance

Enunciado PIAD-425_TRABAJOFINAL (1).pdf, pp. 2-4; archivo datos/arch_financiero.csv; código de preparación y modelos del proyecto; resultados/datos_preparados.csv, metricas.csv y resumen.json. La matriz y las métricas proceden de la ejecución guardada, no de datos inventados.